

面向教育技术应用的公共前置知识图谱对齐与学习支持方法

匿名作者

摘要

数字教育平台正在从资源分发工具转向能够支持过程性诊断、个性化学习路径和可解释教学决策的学习基础设施。对于高校和职业教育中的编程、工程类课程，学习者的笔记、练习记录和问题排查文档持续增长，系统需要在增量数据中识别哪些知识已经具备、哪些前置知识仍然缺失。该问题的核心困难在于：语义相似并不等价于学习前置。仅依赖向量或全文相似度时，平台容易把主题相近的学习记录误连为前置关系，同时漏掉语义表面不相似但学习顺序上必要的基础概念。本文提出公共前置知识图谱对齐方法 PG-Align，将课程、教材或专家知识形成的领域级前置关系作为可审计结构先验，用于约束动态学习者笔记图谱的边预测与缺失知识诊断。方法首先将新增笔记和已有笔记对齐到公共概念图谱，再在公共有向前置图中查询目标概念的直接前置集合，并仅把已被学习者笔记覆盖的直接前置概念投影为学习者图谱边；未被覆盖的直接前置概念则作为学习支持系统的缺失前置知识输出。为验证该机制，本文构建了一个可复现实验基准，包含 48 个 Java/Spring 学习概念、68 条人工定义的有向前置边、432 个训练增量事件和 1080 个测试增量事件。实验结果表明，PG-Align 在直接前置边预测上达到 0.997 精确率、0.990 召回率和 0.994 F1，显著高于相似度基线的 0.282 F1；在缺失前置知识识别上达到 0.984 F1。扰动实验显示，当公共图谱边被 30% 随机扰动时，直接前置边 F1 从 0.994 下降到 0.756，说明方法收益依赖公共前置图谱质量。本文结果表明，公共前置图谱可以为教育技术平台中的增量学习记录组织、前置知识诊断和学习路径推荐提供可解释结构约束，但其在真实教学场景中的效果仍需基于真实学习者数据进一步验证。

关键词：教育技术；前置知识；学习支持；知识图谱对齐；个性化学习；教育数据治理

1 引言

数字教育政策和教育技术应用正在共同推动学习平台从静态资源库转向可诊断、可推荐、可解释的学习支持系统 [1, 2]。在这类系统中，学习者并不是一次性完成全部知识建模，而是在课程学习、项目实践和问题排查过程中持续产生笔记、练习记录和反思文本。与百科式知识图谱不同，学习者笔记图谱具有明显的增量性：节点来自持续新增的学习记录，粒度、命名和表达方式并不稳定，边也无法在系统初始化时一次性构建完成。对教育技术应用而言，最关键的边之一是前置知识边，即理解某个知识点前通常需要先理解的概念或技能。

前置知识发现不能简单等同于语义相似内容召回。以高校软件开发或职业教育中的 Spring Cache 学习为例，与目标笔记最相似的文本可能是另一个 Spring Cache 配置笔记，但真正的前置知识可能包括缓存基础、代理机制、Spring AOP 或 SpEL 表达式。这些概念与目标文本不一定共享大量词项，却决定了学习顺序、作业完成质量和问题排查能力。因此，如果平台在新增学习记录时只检索学习者已有笔记库中最相似的节点并建边，会同时产生两类错误：一是把同主题记录误判为前置关系，二是漏掉不相似但必要的基础概念。对教师、课程平台或学习分析系统而言，这类错误会直接影响学习路径推荐、知识补救和过程性反馈的可信度。

已有教育知识图谱研究已经证明，课程顺序、教材依赖和教育资源中的概念关系可用于学习路径建模和前置关系学习 [3, 4, 5, 6, 7]。GraphRAG 相关工作也表明，图结构可以弥补纯向量检索在全局结构和多跳关系组织上的不足 [8, 9]。然而，将公共前置关系迁移到动态学习者笔记图谱中仍存在一个教育技术落地间隙：公共图谱是课程概念级的，学习者记录是个体表达级的；公共图谱可以由教材、课程标准、专家标注或平台资源预先构建，而学习者图谱只能随学习者更新逐步形成。如何把公共课程知识结构转化为个体学习支持信号，是本文关注的核心问题。

本文提出 PG-Align，一种面向教育技术应用的公共前置知识图谱对齐方法。其核心思想是把“课程结构上应该寻找哪些前置概念”和“学习者已有记录中是否已经覆盖这些概念”分开：前者由公共有向前置图谱决定，后者由笔记到概念的对齐决定。这样，向量或全文检索不再直接决定边是否存在，而只作为概念对齐和候选映射的工具。该设计使学习支持系统能够同时输出已有知识连接和缺失前置知识，为个性化学习路径、教师干预和课程资源推荐提供可解释依据。

本文贡献如下：

- 提出面向教育技术应用的公共前置知识图谱对齐框架，将公共课程概念级前置关系投影到动态学习者笔记图谱。

- 给出直接前置边写入、间接前置路径保留和缺失前置知识诊断的统一形式化定义，使系统输出可用于学习支持和课程诊断。
- 构建一个可复现的受控增量学习记录基准，并比较相似度召回、公共概念相似度、无向图检索、多跳直接写边和 PG-Align。
- 通过覆盖率、消融和公共图谱扰动实验分析方法的有效性、教育技术应用价值与边界条件。

2 相关工作

2.1 数字教育平台与学习支持

数字教育行动计划和人工智能教育治理文件普遍强调，高质量数字学习环境不仅要提供资源，还需要支持学习者差异、过程性反馈和以人为本的技术使用 [1, 2]。在具体平台建设中，这意味着系统需要把课程结构、学习者行为和学习资源组织为可解释的数据对象，而不是只依赖黑盒推荐或文本相似度排序。前置知识图谱为这一目标提供了一个可审计的中间层：教师 and 平台可以明确看到某个推荐、补救建议或学习路径来自哪些课程概念关系。本文的方法属于这一应用方向，即把公共课程知识结构转化为学习者侧的增量诊断信号。

2.2 概念前置关系学习

教育数据中的概念图学习通常从课程材料、学习资源、课程依赖或学生行为中推断概念间关系。Yang 等提出从教育数据中学习概念图结构 [3]；Liang 等利用大学课程依赖恢复概念前置关系 [4]；Lu 等研究教育数据中的概念抽取与前置关系学习 [5]。后续工作进一步采用异构图神经网络和上下文知识建模前置关系 [6, 7]。这些研究主要面向公共教育资源或平台级数据，能够为课程设计和资源组织提供概念级结构；本文进一步关注如何将这类公共概念级前置关系迁移到学习者动态笔记图谱，使其服务于个体层面的学习诊断和技术干预。

2.3 图结构增强检索

GraphRAG 将实体、关系、社区或路径结构引入检索增强生成过程，以提升复杂问题的全局组织和多跳推理能力 [8]。LightRAG 等方法进一步强调图结构在低成本检索和知识组织中的作用 [9]。与这些工作相比，本文不把图结构仅作为问答上下文组织工具，而是将其作为学习者图谱增量建边的结构约束。对于教育技术平台而言，这一点尤为重要：系统不仅要回答学习者的问题，还要解释为什么某个基础概念应被补学、为什么某条学习路径成立。

2.4 学习者知识图谱

学习者知识图谱通常从笔记、作业、练习、对话和资源访问记录中抽取实体关系，用于检索、推荐、学习分析和长期学习档案管理。现有系统常依赖人工双向链接、标签、全文检索或向量相似度形成关系。本文关注一个更细的关系类型：学习前置关系。该关系具有方向性和路径性，因此需要区分直接前置、间接前置和普通相关关系。相比单纯构建个体知识档案，教育技术场景还要求图谱输出能够被教师、平台管理者和学习者理解，因此本文强调公共前置图谱的可审计来源和缺失知识诊断。

3 问题定义

设公共前置知识图谱为

$$G_c = (C, R_c), \quad (1)$$

其中 C 为公共概念集合， $R_c \subset C \times C$ 为有向前置边集合。若 $(c_i, c_j) \in R_c$ ，表示概念 c_i 是理解概念 c_j 的直接前置知识。

设时刻 t 的学习者笔记图谱为

$$G_u^t = (V_u^t, E_u^t, M_u^t), \quad (2)$$

其中 V_u^t 为学习者笔记节点集合， $E_u^t \subset V_u^t \times V_u^t$ 为学习者侧前置边集合， $M_u^t \subset V_u^t \times C$ 为笔记到公共概念的对齐关系。

当新增笔记 v_{new} 到来时，目标是生成 G_u^{t+1} ，并输出两类结果：其一是新增学习者侧前置边集合

$$\Delta E = \{(v_i, v_{new}) \mid v_i \in V_u^t, v_i \text{ 覆盖 } v_{new} \text{ 的直接公共前置概念}\}, \quad (3)$$

其二是缺失前置概念集合

$$\Delta L = \{c_i \mid (c_i, c_{new}) \in R_c, \nexists v_i \in V_u^t : (v_i, c_i) \in M_u^t\}. \quad (4)$$

其中 c_{new} 是新增笔记对齐到的公共概念。这个定义强调，学习者图谱中的直接边只对应公共图谱中的直接前置关系；多跳祖先关系保留为查询路径和学习路径解释，而不默认写成直接边。




图 1: 受控实验中的公共前置知识图谱。节点颜色表示拓扑深度, 箭头表示人工定义的直接前置关系。该图谱包含 48 个概念和 68 条有向边, 用于生成增量笔记事件和评估不同建边策略。

4 方法

4.1 公共图谱约束的概念对齐

PG-Align 的第一步是将新增笔记和已有笔记映射到公共概念集合。给定笔记文本 x , 系统通过别名匹配、关键词召回、向量召回或大语言模型结构化抽取获得候选概念, 并输出最可能的概念 $\hat{c}$ 及其置信度:

$$\hat{c} = \arg \max_{c \in C} s(x, c). \quad (5)$$

本文实验中使用 TF-IDF 词项相似度作为可复现对齐器; 在实际系统中, 该步骤可以替换为领域嵌入模型或带证据约束的大语言模型判断。

4.2 直接前置边投影

完成新增笔记对齐后, 系统在公共图谱中查询目标概念 $\hat{c}_{new}$ 的直接前置集合:

$$P_1(\hat{c}_{new}) = \{c_i \in C \mid (c_i, \hat{c}_{new}) \in R_c\}. \quad (6)$$

随后, 系统检查已有学习者笔记是否覆盖这些公共前置概念。若存在 $(v_i, c_i) \in M_u^t$ 且 $c_i \in P_1(\hat{c}_{new})$, 则写入学习者侧前置边 (v_i, v_{new}) 。该步骤使边的方向和语义由公共图谱决定, 而不是由笔记文本之间的相似度决定。

4.3 多跳路径保留与缺失前置诊断

公共图谱中的多跳祖先可用于解释学习路径, 但不应全部写成直接边。定义 $P_k(c)$ 为 k 跳以内的前置祖先集合。若 $c_i \in P_k(c_{new})$ 且 $c_i \notin P_1(c_{new})$, 系统默认只在查询时返回路径解释, 而不直接加入 E_u 。这样可以避免学习者图谱迅速变得稠密, 并保留教师或平台对学习路径解释粒度的控制。

对于直接前置集合中未被学习者笔记覆盖的概念, 系统输出缺失前置集合 ΔL 。这使系统不仅能连接已有知识, 还能指出学习者尚未建立记录的基础知识, 从而支持补救资源推荐、学习计划调整和教师干预。

5 实验设置

5.1 受控增量学习记录基准

由于公开的学习者笔记前置边标注数据较少, 本文构建了一个受控增量学习记录基准, 用于验证方法机制而非声称覆盖真实教学分布。基准面向高校或职业教育中的 Java/Spring 软件开发学习路径, 包含 48 个概念和 68 条有向前置边, 如图 1 所示。每个概念包含英文名称、中文别名和简短描述。实验程序根据概念描述生成学习记录文本, 并加入少量无关概念词项作为文本噪声。

表 1: 受控增量学习记录基准上的主结果。边预测指标衡量学习者图谱直接前置边, Missing F1 衡量缺失直接前置概念识别, Edges/note 越低表示写入图谱的直接边越稀疏。

方法	精确率 $\uparrow$	召回率 $\uparrow$	边 F1 $\uparrow$	Missing F1 $\uparrow$	Edges/note $\downarrow$
Similarity-only	0.173	0.766	0.282	0.000	5.09
Public-similarity	0.385	0.331	0.356	0.136	0.99
Undirected graph	0.388	0.994	0.558	0.000	2.94
2-hop-as-direct	0.391	0.993	0.561	0.984	2.91
PG-Align	0.997	0.990	0.994	0.984	1.14

每个测试样本模拟一次新增学习记录事件。给定目标概念, 程序按覆盖率参数随机决定其直接前置概念是否已存在于学习者笔记中, 并加入若干多跳祖先和干扰概念作为已有笔记。若某个直接前置概念已有对应笔记, 则该概念对应的笔记到新增笔记之间存在金标准前置边; 若没有对应笔记, 则该概念为金标准缺失前置知识。实验使用 432 个训练事件调节相似度阈值, 使用 1080 个独立测试事件报告结果。该基准不替代真实学校部署评估, 但可以检验不同建边机制在可控前置关系条件下的行为差异。

5.2 比较方法

本文比较五种策略:

- **Similarity-only:** 直接计算新增笔记与已有笔记的 TF-IDF 相似度, 超过训练集调节阈值即建边, 代表常见的相似学习资源推荐思路。
- **Public-similarity:** 将新增笔记与所有公共概念做文本相似度匹配, 将高相似公共概念视为前置候选。
- **Undirected graph:** 忽略公共图谱边方向, 召回目标概念两跳内的无向邻居并投影到学习者笔记。
- **2-hop-as-direct:** 使用公共图谱方向, 但把两跳以内祖先全部写为学习者图谱直接前置边。
- **PG-Align:** 仅将公共图谱中的直接前置概念投影为学习者图谱直接边, 并输出未覆盖的直接前置概念。

5.3 评价指标

直接前置边预测采用精确率、召回率和 F1。缺失前置知识识别同样采用 F1。为评估图谱稠密度, 本文报告平均每个新增笔记写入的预测边数; 在教育技术平台中, 过密图谱会降低教师审阅、学习者理解和后续推荐解释的可用性。所有阈值只在训练事件上调节, 测试结果在独立事件上计算。

6 实验结果

6.1 直接前置边预测

表 1 和图 2 显示, Similarity-only 的召回率达到 0.766, 但精确率仅为 0.173, 说明相似度基线倾向于写入大量主题相关但非前置的边。Public-similarity 只利用新增笔记与公共概念的表面相似度, 边 F1 为 0.356, 表明仅在公共概念空间做相似召回仍不能可靠识别前置关系。

忽略图谱方向的 Undirected graph 方法达到 0.994 召回率, 但精确率仅为 0.388, 说明公共图谱的连接性有助于覆盖候选, 但方向信息对直接前置判断至关重要。2-hop-as-direct 同样获得高召回率, 但由于把间接祖先写为直接边, 精确率仅为 0.391。相比之下, PG-Align 只写入直接前置边, 达到 0.997 精确率、0.990 召回率和 0.994 F1, 同时平均每个新增笔记仅写入 1.14 条边。

6.2 学习者笔记覆盖率影响

图 3 比较不同前置笔记覆盖率下的边预测 F1。随着覆盖率从 0.2 增加到 0.9, Similarity-only 的 F1 从 0.175 增加到 0.323, 但始终受误连边影响。相比之下, PG-Align 在低覆盖率下仍达到 0.988 F1, 并在不同覆盖水平下保持稳定。这说明公共图谱约束并不要求学习者图谱已经完整; 只要存在的学习记录能被正确对齐, 系统即可把已有前置知识投影为边, 把未覆盖部分输出为缺失知识。对教育技术应用而言, 这一点对应了实际场景中的“边用边建”: 平台不需要等待学习者资料完整, 仍可逐步提供可解释反馈。




图 2: 不同建边策略的直接前置边 F1。相似度召回和无向图检索能够找到部分候选, 但会引入大量非直接前置边; PG-Align 通过公共有向直接前置约束显著提高 F1。

6.3 公共图谱扰动鲁棒性

为了评估公共前置图谱质量对方法的影响, 本文随机删除并添加一定比例的公共图谱边。图 4 显示, 扰动率为 0.05 时, 直接边 F1 从 0.994 降至 0.953; 扰动率为 0.30 时, 直接边 F1 降至 0.756, 缺失前置识别 F1 降至 0.601。这一结果说明, PG-Align 的优势来自公共图谱结构, 因此公共图谱质量是关键边界条件。该方法不应被理解为无需维护公共图谱的自动建边方案, 而应被视为把可审计的课程前置先验迁移到学习者图谱中的机制。

7 教育技术应用与政策讨论

实验结果支持三个面向教育技术应用的结论。第一, 前置知识诊断不应直接等同于相似学习资源召回。Similarity-only 具有较高召回率, 却显著牺牲精确率, 导致学习者图谱过密, 并可能向学习者或教师展示大量“相关但并非前置”的误导性连接。第二, 公共图谱必须保留方向和直接边语义。无向图检索和多跳直接写边都能召回大量相关概念, 但无法区分直接前置与间接背景知识, 不适合直接作为补救教学或学习路径推荐的依据。第三, 缺失前置知识识别是学习支持系统的重要输出。对于尚未出现在学习者记录中的直接前置概念, 系统应输出缺失项, 而不是强行连接低置信度相似节点。

从教育政策和平台治理角度看, PG-Align 的价值在于把个性化学习支持建立在可审计的课程结构之上, 而不是完全依赖不可解释的相似度排序。公共前置图谱可以来自课程标准、教材章节、教学大纲、专家标注和平台资源结构; 学习者图谱则只保存其已有记录与公共概念之间的对齐关系。这种分层设计有助于数据最小化和责任划分: 公共图谱由课程或平台侧维护, 学习者数据用于个体诊断, 系统输出的每条前置边都可以回溯到公共概念关系。

本文也存在明确限制。实验基准是受控构造的, 概念、前置边和笔记文本均由程序生成, 不能替代真实教学平台中的学习者数据。公共图谱扰动实验表明, 当公共前置边本身错误较多时, 方法性能会明显下降。因此, 实际系统需要结合教材结构、课程顺序、专家校验、学习者反馈和大语言模型证据抽取来持续维护公共图谱。本文没有声称 PG-Align 能自动发现所有领域的正确前置关系; 它解决的是在已有公共前置先验条件下, 如何把该先验可解释地迁移到动态学习者笔记图谱, 并转化为学习支持信号。

8 结论

本文提出 PG-Align, 一种面向教育技术应用的公共前置知识图谱对齐与学习支持方法。该方法将新增学习记录对齐到公共概念图谱, 通过公共有向直接前置关系约束学习者图谱建边, 并将未覆盖的直接前置概念输出为缺失知识。受控实验表明, PG-Align 相比相似度建边显著提高直接前置边 F1, 并能保持较低图谱稠密度。扰动实验进一步表明, 公共图谱质量是方法有效性的主要边界。未来工作应构建真实教学场景下的学习者笔记标注集, 引入可审计的证据抽取与反馈闭环, 并评估该方法对学习路径推荐、补救资源推送和课程实施改进的实际收益。




图 3: 前置笔记覆盖率对直接前置边 F1 的影响。覆盖率表示目标概念的直接前置概念已存在于学习者笔记中的概率。




图 4: 公共图谱边扰动对 PG-Align 的影响。扰动同时包含随机删边和随机加边；直接边预测和缺失前置识别均随公共图谱质量下降而退化。

参考文献

- [1] European Commission. Digital Education Action Plan 2021–2027: Resetting education and training for the digital age. COM(2020) 624 final, 2020.
- [2] UNESCO. Guidance for Generative AI in Education and Research. United Nations Educational, Scientific and Cultural Organization, 2023.
- [3] Y. Yang, H. Liu, J. G. Carbonell, and W. Ma. Concept Graph Learning from Educational Data. In *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining*, pages 159–168, 2015.
- [4] C. Liang, J. Ye, Z. Wu, B. Pursel, and C. L. Giles. Recovering Concept Prerequisite Relations from University Course Dependencies. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 4786–4791, 2017.
- [5] W. Lu, Y. Zhou, J. Yu, and C. Jia. Concept Extraction and Prerequisite Relation Learning from Educational Data. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 9678–9685, 2019.

- [6] C. Jia, Y. Shen, Y. Tang, L. Sun, and W. Lu. Heterogeneous Graph Neural Networks for Concept Prerequisite Relation Learning in Educational Data. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 2036–2047, 2021.
- [7] H. Sun, Y. Li, and Y. Zhang. ConLearn: Contextual-knowledge-aware Concept Prerequisite Relation Learning with Graph Neural Network. In *Proceedings of the 2022 SIAM International Conference on Data Mining*, pages 118–126, 2022.
- [8] D. Edge, H. Trinh, N. Cheng, J. Bradley, A. Chao, A. Mody, S. Truitt, D. Metropolitansky, R. O. Ness, and J. Larson. From Local to Global: A Graph RAG Approach to Query-Focused Summarization. arXiv preprint, 2024.
- [9] Z. Guo, L. Xia, Y. Yu, T. Ao, and C. Huang. LightRAG: Simple and Fast Retrieval-Augmented Generation. arXiv preprint, 2024.